

# **Chapitre 11**

## **Tests statistiques sur les corrélations et régressions**

# Rappel

## Relation entre X et Y :

	X	Y
Sujet 1	100	56
Sujet 2	80	87
...	...	...

$$\overline{X}, S_X$$

$$\overline{Y}, S_Y$$

$$r = \frac{\text{COV}_{XY}}{S_X S_Y}$$

$$\hat{Y} = bX + a$$

$$S_{Y \cdot X}$$

# Corrélation ou régression

---

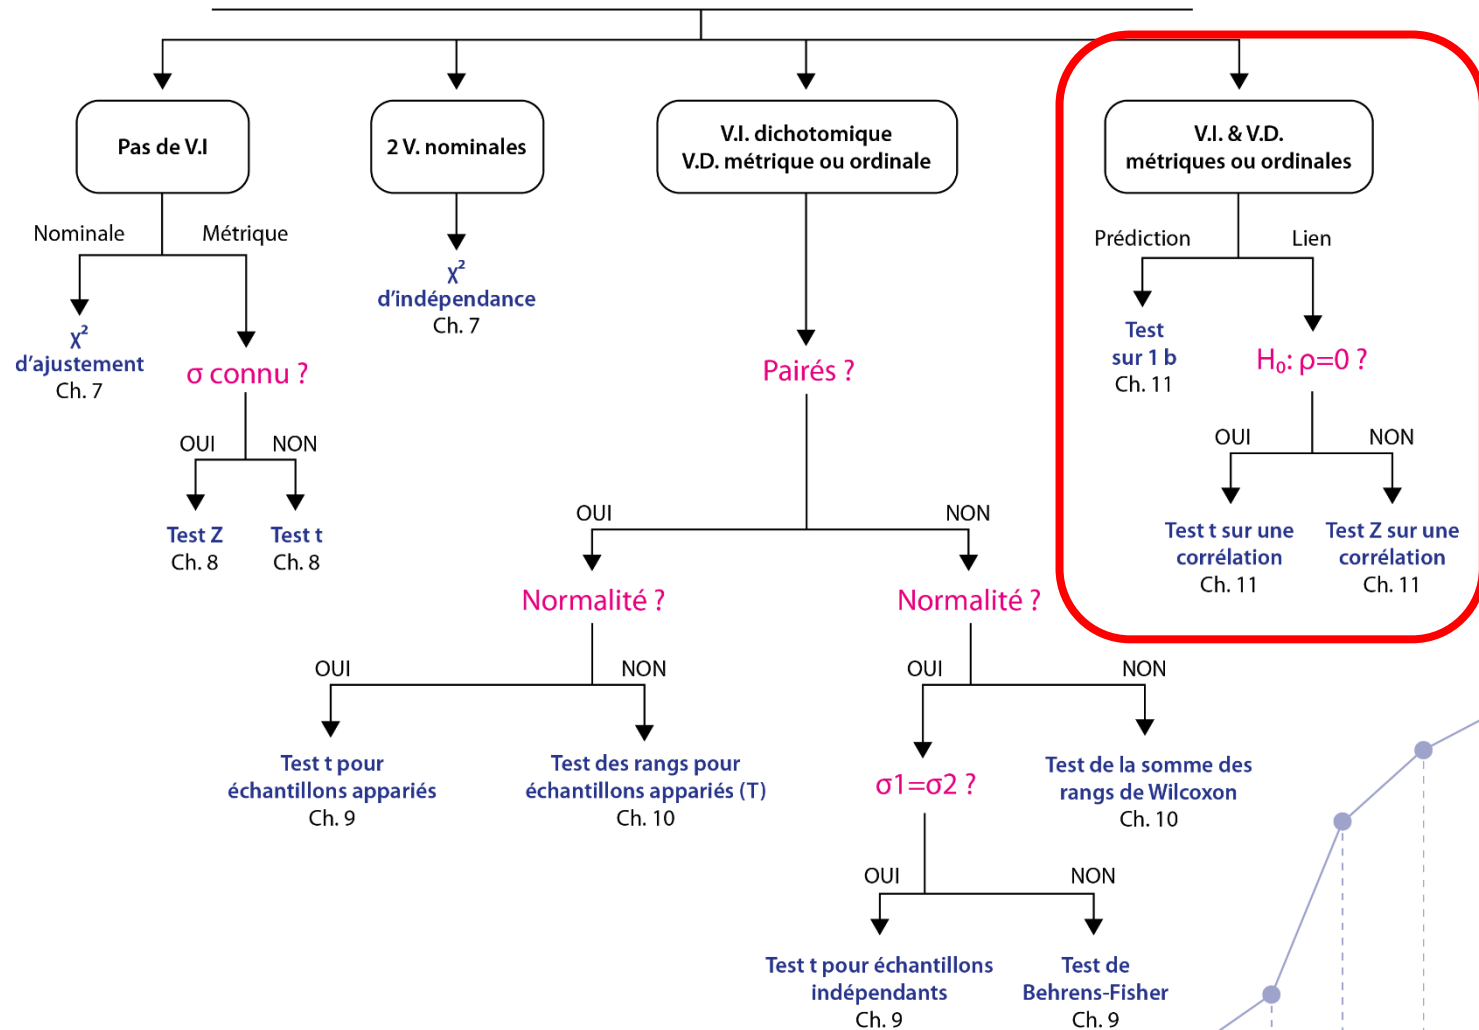
Coefficient de corrélation }  
Droite de régression } = description

Quid de la population ?

Problème de l'erreur d'échantillonnage

# Choisir le bon test d'hypothèse

## Identifier les variables et déterminer leurs natures



# Notation

## Echantillon

$r$

$b$

$a$

## Population

$\rho$  (rho)

$\beta$

$\alpha$

# Les tests statistiques

## Différents tests sur une relation

$$H_0 : \rho = 0$$

$$H_A : \rho \neq 0$$

$$H_0 : \rho = 0,5$$

$$H_A : \rho \neq 0,5$$

$$H_0 : \beta = 0$$


$$H_A : \beta \neq 0$$

$$H_0 : \beta = 0,5$$

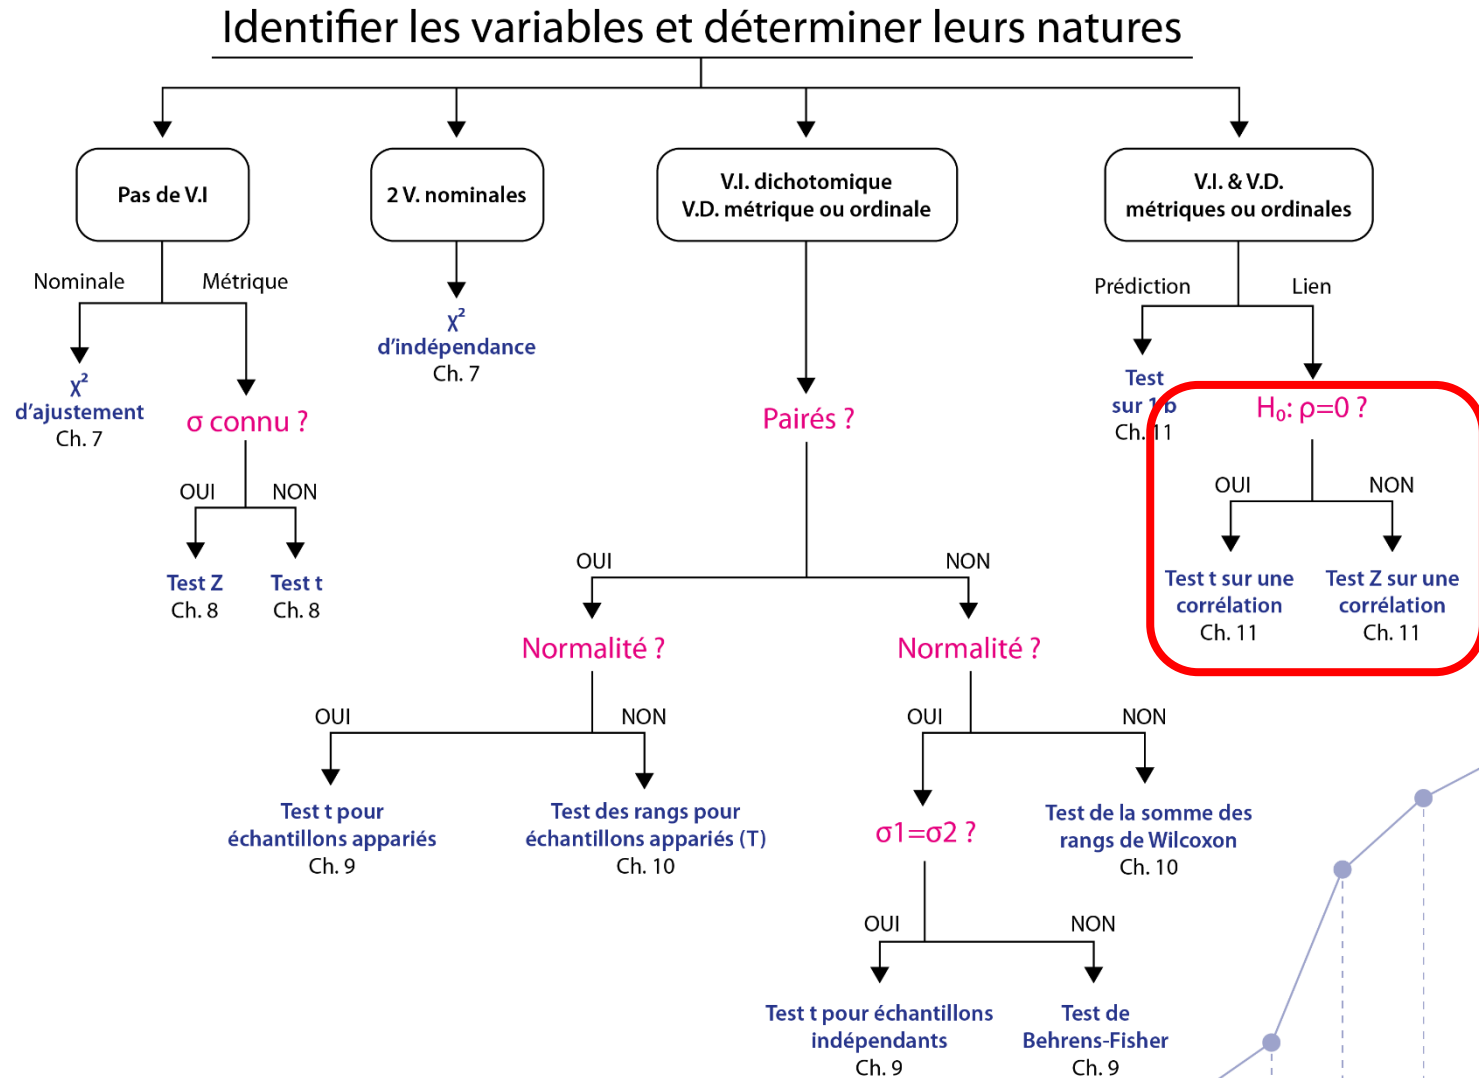
$$H_A : \beta \neq 0,5$$

# Tests sur un coefficient de corrélation

---



# Choisir le bon test d'hypothèse





# Tester $\rho = 0$

Pour  $\rho = 0$ ,  $r$  est plus ou moins normalement distribué autour de zéro avec:

$$S_r = \sqrt{\frac{1 - r^2}{N - 2}}$$

# Tester $\rho = 0$

Dès lors:

$$t_{obs} = \frac{r}{S_r}$$

Avec  $N - 2$  dl

# Exemple

Y a-t-il une relation positive entre indice d'inégalité des revenus et prévalence des troubles de l'humeur ?

$$N = 9$$

$$dl = 9 - 2 = 7$$

$$r = 0,72$$

$$\alpha = 0,05$$

# Example

$$H_0 : \rho = 0$$

$$H_A : \rho > 0$$

$$S_r = \sqrt{\frac{1 - r^2}{N - 2}} = \sqrt{\frac{1 - 0,52}{9 - 2}} = 0,26$$

# Exemple

$$t_{obs} = \frac{r}{S_r} = \frac{0,72}{0,26} = 2,77$$

$$t_{0,05} = 1,895 \text{ (test unilatéral et 7 dl)}$$

Puisque  $2,77 > 1,895$ , rejeter  $H_0$

# Exemple

---

**Il y a bien une corrélation positive significative entre indice d'inégalité des revenus et prévalence des troubles de l'humeur.**

# Tester rho = une valeur

---

$$H_0 : \rho = 0,5$$

$$H_A : \rho < 0,5$$

Pour  $\rho \neq 0$ ,  $r$  n'est pas distribué  
normalement

# Tester rho = une valeur

---

Solution de Fisher:

Transformer  $r$  en  $r'$  selon:

$$r' = 0,5 \times \ln\left(\frac{1+r}{1-r}\right)$$



# Tester rho = une valeur

---

$r'$  est normalement distribué autour de  $\rho'$

avec :

$$S_{r'} = \frac{1}{\sqrt{N-3}}$$

# Tester rho = une valeur

Dès lors:

$$Z = \frac{r' - \rho'}{\sqrt{\frac{1}{N-3}}}$$

# Exemple

La corrélation entre indice d'inégalité des revenus et prévalence des troubles de l'humeur est-elle inférieure à 0,9 ?

$$N = 9$$

$$dl = 9 - 2 = 7$$

$$r = 0,72$$

$$\alpha = 0,05$$

# Example

$$H_0 : \rho = 0,9$$

$$H_A : \rho < 0,9$$

$$r = 0,72 \longrightarrow r' = 0,908$$

$$\rho = 0,9 \longrightarrow \rho' = 1,472$$

# Example

$r$	$r'$	$r$	$r'$
...	...	...	...
0.690	0.848	0.890	1.422
0.695	0.858	0.895	1.447
0.700	0.867	0.900	1.472
0.705	0.877	0.905	1.499
0.710	0.887	0.910	1.528
0.715	0.897	0.915	1.557
...	...	...	...

# Example

---

$$Z = \frac{r' - \rho'}{\sqrt{\frac{1}{N-3}}} = \frac{0,908 - 1,472}{\sqrt{\frac{1}{6}}} = -1,38$$

# Example

$$H_0 : \rho = 0,9$$

$$H_A : \rho < 0,9$$

$$P(r < 0,72) = P(Z < -1,38) =$$

$$P(Z > 1,38) = 0,0838$$

# Exemple

---

Puisque  $0,0838 > 0,05$ , ne pas rejeter  $H_0$

Nous n'avons pas suffisamment de preuves pour affirmer que la corrélation entre indice d'inégalité des revenus et prévalence des troubles de l'humeur est inférieure à 0,9.



# Intervalle de confiance

---

**Calculer un intervalle de confiance pour  $\rho$  à partir de  $r$**

**Exemple: Estimer la corrélation entre indice d'inégalité des revenus et prévalence des troubles de l'humeur pour l'ensemble des pays.**

# Intervalle de confiance

$$IC(\rho') = r' \pm Z_{\alpha/2} \frac{1}{\sqrt{N-3}}$$

$$IC(\rho') = 0,908 \pm 1,96 \frac{1}{\sqrt{6}} = 0,908 \pm 0,8$$

# Intervalle de confiance

---

$$0,108 < \rho' < 1,708$$

Devient

$$0,11 < \rho < 0,935$$

# Example

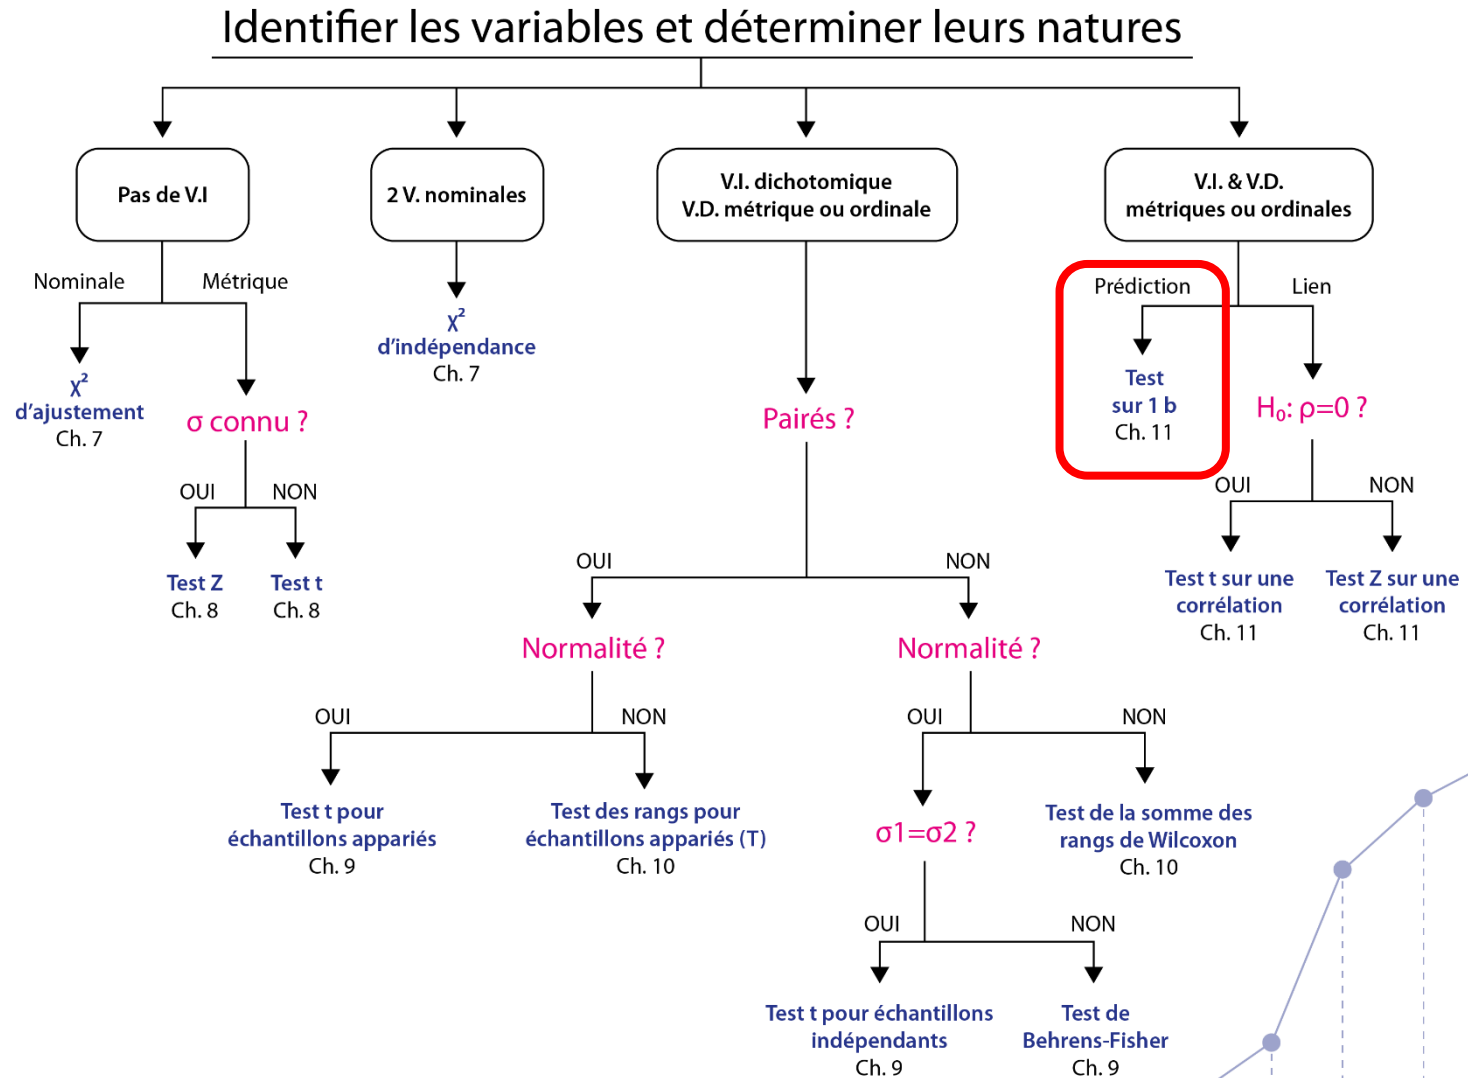
$r$	$r'$	$r$	$r'$
...	...	...	...
0.725	0.918	0.925	1.623
0.730	0.929	0.930	1.658
0.735	0.940	0.935	1.697
0.740	0.950	0.940	1.738
0.745	0.962	0.945	1.783
0.750	0.973	0.950	1.832
...	...	...	...

# Intervalle de confiance

---

**On peut donc affirmer avec une certitude de 95% que la corrélation entre indice d'inégalité des revenus et prévalence des troubles de l'humeur dans la population générale se trouve entre 0,110 et 0,935.**

# Choisir le bon test d'hypothèse



# Tester b

---

**b** est normalement distribué avec une erreur standard égale à :

$$S_b = \frac{S_{Y \cdot X}}{S_X \sqrt{N-1}}$$

# Tester b

Dès lors:

$$t_{obs} = \frac{b - \beta}{S_b}$$

Avec  $N - 2$  dl



# Exemple

---

**Peut-on affirmer que le taux de prévalence des troubles de l'humeur augmente de plus de 2% pour une augmentation de 0,1 unité sur l'indice d'inégalité des revenus ?**

# Exemple

$$H_0 : \beta = 20$$

$$H_A : \beta > 20$$

$$N = 9 \quad dl = 9 - 2 = 7 \quad \alpha = 0,05$$

$$S_x = 0,0819 \quad S_{Y.X} = 5,00$$

$$b = 59,328$$

# Example

$$S_b = \frac{S_{Y.X}}{S_X \sqrt{N-1}} = \frac{5}{0,0819 \sqrt{8}} = 21,58$$

$$t_{obs} = \frac{b - \beta}{S_b} = \frac{59,328 - 20}{21,58} = 1,82$$

# Exemple

---

$$t_{\text{obs}} = 1,82$$

$$t_{0,05} = 1,895 \text{ (test unilatéral et 7 dl)}$$

Puisque  $1,82 < 1,895$ , ne pas rejeter  $H_0$

# Exemple

---

**Nous n'avons pas de preuves suffisantes pour affirmer que le taux de prévalence des troubles de l'humeur augmente de plus de 2% pour une augmentation de 0,1 unité sur l'indice d'inégalité des revenus.**

# Intervalle de confiance

---

**Calculer un intervalle de confiance pour  $\beta$  à partir de  $b$**

**Exemple: Estimer la pente de la régression entre indice d'inégalité des revenus et prévalence des troubles de l'humeur.**

# Intervalle de confiance

---

$$IC_{0,95} = b \pm t_{\alpha/2} S_b$$

$$IC_{0,95} = 59,328 \pm (2,365 \times 21,58)$$

$$= 59,328 \pm 51,037$$

# Intervalle de confiance

---

$$8,291 < \beta < 110,365$$

Pour une augmentation de 0,1 point sur l'échelle d'inégalité des revenus, le taux de prévalence des troubles de l'humeur augmente entre 8 et 11%.



# Conditions d'application

---

## Condition 1 (rappel)

Linéarité de la régression

La relation entre  $X$  et  $Y$  est linéaire

# Conditions d'application

---

## Autres conditions

Uniquement pour les tests d'hypothèse



# Conditions d'application de la régression

---

1. Homogénéité des variances

2. Normalité dans les vecteurs

# Conditions d'application de la régression



# Conditions d'application de la corrélation

---

## Distribution normale bivariée:

- $X$  et  $Y$  sont normalement distribués
- Pour tout  $X$ , les  $Y$  sont normalement distribués
- Pour tout  $Y$ , les  $X$  sont normalement distribués

# En cas de violation des conditions

---

**1. Tests très robustes**

**2. Tests non paramétriques sur les rangs**